

Plan de collecte et de gouvernance des données

Projet: Prédiction de la population du Canada et estimation des centres de santé

Membres: Wassim, Kosseila, Walid

Date: 9 février 2026

1. Objectif des données

Le Canada connaît une croissance démographique soutenue, principalement portée par l'immigration. Les planificateurs du système de santé ont besoin d'anticiper les besoins futurs en infrastructures hospitalières pour une population en évolution constante.

Variables d'entrée X: année, population précédente, naissances, décès, immigration, émigration, taux de natalité, taux de mortalité, solde naturel, solde migratoire

Variable cible y: population totale du Canada

2. Types de données et sources

Type de données

Données tabulaires structurées en format CSV. Ce type est justifié car les données démographiques sont naturellement organisées en séries temporelles avec des variables numériques mesurables annuellement.

Sources de données

Source 1: Statistique Canada - Estimations démographiques

Description: Estimations annuelles de la population canadienne, incluant les composantes de la croissance démographique

Méthode d'accès: Téléchargement direct depuis le site web de Statistique Canada, tableaux 17-10-0005-01 et 17-10-0008-01

Qualité: Données officielles, complètes, validées par l'agence nationale de statistique. Aucun doublon, séries continues de 1980 à 2023

Source 2: Institut canadien d'information sur la santé - ICIS

Description: Nombre d'établissements hospitaliers au Canada

Méthode d'accès: Consultation des rapports annuels publics de l'ICIS

Qualité: Données de référence pour le ratio population par hôpital. Donnée ponctuelle utilisée comme constante

3. Permissions et consentement

Statistique Canada

Licence: Licence ouverte du gouvernement du Canada. Les données sont librement réutilisables à des fins commerciales et non commerciales avec mention de la source.

ICIS

Licence: Données publiques accessibles dans les rapports officiels. Utilisation permise avec citation de la source.

Consentement

Non applicable. Les données utilisées sont des statistiques agrégées au niveau national. Aucune donnée individuelle ou personnelle n'est collectée ou traitée.

4. Protection des données

Données personnelles: Non

Les données utilisées sont exclusivement des statistiques agrégées publiées par des organismes gouvernementaux. Elles ne contiennent aucune information permettant d'identifier directement ou indirectement un individu.

Mesures de protection

Anonymisation: Non requise car les données sont déjà agrégées au niveau national

Pseudonymisation: Non applicable

Stockage: Les fichiers CSV sont stockés localement dans le répertoire du projet avec accès restreint aux membres

Transmission: Aucune transmission de données sensibles. Le code et les données agrégées peuvent être partagés librement

5. Risques de biais et représentativité

Risques identifiés

Risque 1: Biais de sélection temporelle

Les données couvrent 1980 à 2023. Les tendances récentes comme l'augmentation massive de l'immigration depuis 2021 pourraient ne pas être pleinement représentées dans un modèle entraîné sur l'ensemble de la période.

Risque 2: Biais de mesure

Les méthodes de collecte de Statistique Canada ont évolué au fil du temps. Les estimations intercensitaires peuvent présenter des écarts avec les chiffres réels révélés lors des recensements.

Risque 3: Sous-représentation des changements de politique

Les changements brusques de politique d'immigration ne sont pas capturés par les variables actuelles. Le modèle suppose une continuité des tendances qui pourrait ne pas se vérifier.

Actions de mitigation

Action 1: Pondérer davantage les années récentes dans l'entraînement du modèle pour mieux capturer les tendances actuelles

Action 2: Implémenter un mécanisme de ré-entraînement annuel avec les nouvelles données publiées par Statistique Canada pour corriger les écarts

Annexe: Inventaire des données

Source	Type	Public/Private	Permissions	Données personnelles	Protections	Risques	Actions
Statistique Canada	Tableau CSV	Public	Licence ouverte	Non	Données agrégées	Biais temporel, mesure	Pondération, ré-entraînement
ICIS	Rapport	Public	Citation requise	Non	Données agrégées	Ratio fixe	Mise à jour annuelle